

中央财经大学 2023-2024 (2) 学期

期末报告

课程名称	数据可视化		
作业性质	期末报告	评阅人	
计分项		分值	得分
数据可视化应用的恰当性		30	
数据可视化形式的丰富性		25	
数据可视化呈现的美观度		15	
基于可视化的分析清晰合理		10	
报告内容完整，语言通顺，格式规范		10	

学号	姓名	所在学院及专业	贡献分	总分
2022311616	刘澍泽	管理科学与工程学院 大数据管理与应用 22		
2022311632	吴戈瑶	管理科学与工程学院 大数据管理与应用 22		
2022311633	彭朗	管理科学与工程学院 大数据管理与应用 22		

小组成员分工描述：

图表制作

引文数据柱状图：刘澍泽

作图工具：pyecharts

算法性能气泡图：彭朗

作图工具：pyecharts

网络模型结构图：吴戈瑶

作图工具：pytorch netron

（其中 ZFNet 无现成网络，其架构由刘澍泽用 pytorch 搭建）

网页搭建：彭朗

报告撰写：吴戈瑶 刘澍泽

三人贡献比例均为 1/3

目 录

1	计算机视觉与 CNN	1
1.1	计算机视觉及主要任务	1
1.2	CNN 的工作原理	1
2	ILSVRC 竞赛与 ImageNet 数据集	3
3	可视化部分——历年经典 CNN 模型	4
3.1	AlexNet (2012)	4
3.2	ZFNet (2013)	5
3.3	VGG (2014)	6
3.4	GoogLeNet (2014)	7
3.5	ResNet (2015)	9
3.6	GBD-Net (2016)	9
3.7	SENet (2017)	10
3.8	对可视化的解释	10
4	CNN 走向何方?	13
4.1	持续优化! ——DenseNet, EfficientNet	13
4.2	目标检测——CNN 还能走多远?	14
4.3	Transformer——廉颇老矣, 尚能饭否?	15

CNN 与图像分类——从 ILSVRC 竞赛看 CNN 的发展历程

1 计算机视觉与 CNN

1.1 计算机视觉及主要任务

计算机视觉是一门研究如何让机器“感知”周围环境的学科，主要通过对采集的图片或视频进行处理以获得相应场景的三维信息，主要任务包括图像分类、目标检测、语义分割等。

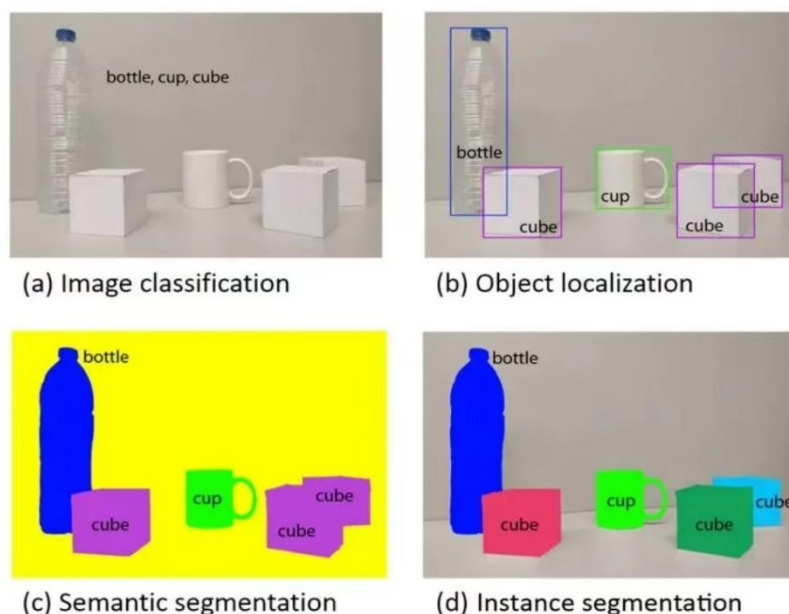


Figure 1 计算机视觉的主要任务

对于计算机视觉的研究与应用可以追溯到 20 世纪 50 年代。最初采用基于 2D 图像处理的方法，其不足在于易受各种环境因素的影响，紧接着产生了多角度的 3D 点云建模与分割方法。经过漫长的研究发展，随着机器学习时代的开启，机器学习与深度学习算法被融入到图像识别当中，以支持向量机为基础的图像分类算法出现。而随着卷积神经网络（CNN）的提出，图像识别的速度和精准度得到了大幅提升。在此阶段，图像识别功能已经具有较为良好的动态视觉，而当前形态下基于语义分割的方法研究也取得突破。

1.2 CNN 的工作原理

卷积神经网络（CNN）是主要针对图像检测开发的神经网络，其算法运行模式可简单理解为反复的特征提取——降维过程最终得到线性特征编码，编码投入机器学习的过程，以下对其过程进行简单阐述：

- Conv 卷积：卷积即是提取特征。卷积过程使用一个卷积核（特征）按照步长在像素矩阵上进行扫描，基于对应位置相乘并求和的方法，生成较小的新矩阵，即特征图。




Figure 2 卷积核工作原理

- ReLU 激活：初始像素矩阵的元素值分布在 $(-1, 1)$ ，使用此迁跃函数激活，将负数规范成 0，使特征图矩阵规范化。
- Pooling 池化：池化即降维，形象地说，就是近视眼摘掉眼镜看图像。我们认为特征图中相邻元素具有相似特征，可以使用区域的特征值代替所有值，即部分保留防止冗余，压缩空间，一定程度控制过拟合。
- Padding 边缘：在一次卷积操作中，处于特征图中部的数据元素被多次扫描，而边缘的扫描次数相对较少，这会使我们忽略一些重要的边缘特征。因此可以在特征图外缘补 0，增加原本边缘数据元素的扫描次数，同时在最大池化操作下，不会引入误差信息。
- FC 全连接：当特征图与卷积核大小相近时，对其进行扁平化处理并全连接成一个一维向量，方便后续赋权、相似性对比并反向传播的机器学习操作。

一个卷积神经网络通常包含多个卷积层和池化层穿插排列，最终连接几层全连接网络，进行输出。学习时，反向传播分别学习赋权和卷积核选取；使用时，输出与每个目标向量的相似度，即图像包含该物体的概率。

2 ILSVRC 竞赛与 ImageNet 数据集

想要了解 CNN 发展历程就不得不提到一个比赛——ILSVRC (ImageNet Large Scale Visual Recognition Challenge)，它主要评估大规模的图像识别和目标检测算法，是近年来计算机视觉领域最具权威也最具影响力的学术竞赛之一。

比赛包括多个挑战赛道，如目标检测、场景分类、图像分割等，要求参赛队伍使用先进的计算机视觉技术从图片或视频中提取信息，以完成分类或检测的任务。对于各个模型和算法，主要的评价指标是其准确率，具体包括 Top-5 错误率和 Top-1 错误率。Top-5 错误率是指在测试集中，分类器的前 5 个预测结果中没有正确答案的比率，即在 5 次机会中只要有正确答案就算预测正确；Top-1 错误率则是指分类器预测的第一个选项就不正确的比率。各个队伍需要使用给定数据集对算法进行训练和改进，以提高准确率和鲁棒性。



Figure 3 ImageNet 数据集

ImageNet 数据集是 ILSVRC 竞赛使用的数据集，由斯坦福大学李飞飞教授主导，耗费大量人力、通过各种方式和平台收集制作而成，包含了超过 1400 万张全尺寸的有标记图片，涵盖了 2 万多个类别。作为深度学习发展起来的关键因素，庞大的数据能够将算法训练得更准确完善，可以说在当时的情况下像 ImageNet 这样的大规模数据集大大推动了深度学习的发展。ILSVRC 竞赛每年会从 ImageNet 数据集中抽出部分样本，以 2012 年为例，比赛的训练集包含 1281167 张图片，验证集包含 50000 张图片，测试集为 100000 张图片。

ILSVRC 竞赛一方面能够允许研究人员使用自己的模型对于更大规模、更多种类的对象数据进行识别和检测，以比较相互之间的研究方法与研究进展；另

一方面，ILSVRC 展示最先进的技术，衡量着整个计算机视觉领域已经到达的高度。ILSVRC 竞赛为技术进步和应用创新提供了强大动力，推动计算机视觉领域的发展，并加速推广人工智能在各个行业的广泛应用。

3 可视化部分——历年经典 CNN 模型

ILSVRC 竞赛从 2010 年开始举办。随着深度学习技术的日益发展，各种神经网络算法在比赛中屡创佳绩，机器视觉的错误率逐年下降甚至已经低于人类视觉的错误率，再举办类似的比赛意义没有那么大了，因此在 2017 年，最后一届 ILSVRC 落下了帷幕。

虽然比赛不再进行，但 ILSVRC 对深度学习和计算机视觉技术的迅速发展有着深远影响和巨大贡献，短短八年间我们也见证了很多经典网络模型的出现和不断发展改进，在此我们以 2012 年起每一届 ILSVRC 冠军和部分表现突出的模型为例，来研究和展示 CNN 的发展历程。

3.1 AlexNet (2012)

AlexNet 将 ImageNet 的识别错误率从 26.2% 降到了 15.3%，在 2012 年的竞赛中脱颖而出。这个模型在 CNN 发展史上具有重大意义，标志着深度学习技术在图像识别任务上的重大突破，使计算机视觉模型不再仅仅是学术 demo，而是成为商业化产品，从而将深度学习和 CNN 的名声突破学术界，在产业界一鸣惊人，并引发了随后几年深度学习领域的迅速发展。

AlexNet 是一个 8 层深度的 CNN 网络，其中包括 5 个卷积层和 3 个全连接层。AlexNet 的特点和创新有：

(1) 使用 ReLU 作为激活函数，由于 ReLU 是非饱和函数，解决了饱和函数在网络比较深时的梯度消失问题，提高了随机梯度下降的收敛速度。

(2) 在前两个全连接层引入 Dropout，使这两个全连接




Figure 4 AlexNet 网络结构

层的神经元以一定的概率失去活性，不再参与传播。做预测时，将所有神经元的输出乘 Dropout 值。这一机制有效缓解了模型的过拟合问题。

(3) 采用重叠的最大池化，避免了先前 CNN 中普遍使用的平均池化带来的模糊化效果。同时使用小于核尺寸的池化步长，在池化层的输出之间形成重叠，提升了特征的丰富性。

(4) 提出 LRN 层，即局部响应归一化，对局部神经元的活动创建竞争机制，使得响应较大的特征更加显著，并抑制反馈较小的神经元，提高了模型的泛化能力。

(5) 使用 GPU 加速，加快了模型的训练速度，同时也意味着可以训练更大规模的神经网络模型。

(6) 数据增强，在训练过程中随机从 256×256 的原始图像中截取 224×224 大小的区域并进行水平翻转和颜色变化，相当于增强了 $(256-224) \times (256-224) \times 2 = 2048$ 倍的数据量。大大增加了样本数量，使得模型能够学习不同位置的多种特征，减轻过拟合，提升泛化能力。




Figure 5 AlexNet 对应论文引用量

3.2 ZFNet (2013)

ZFNet 是 2013 年分类任务的冠军，它在 AlexNet 的基础上对卷积核和步幅进行了改进，并引入了可视化技术，主要的亮点有：

- (1) 反卷积，即卷积操作的逆过程，将特征映射到像素上。
- (2) 反池化，原本池化是不可逆的过程，而 ZFNet 记录了池化过程中最大激活值的坐标，在反池化时只激活该坐标的值，其它的值置为 0，得到一种近

似的逆。

(3) 反激活，与激活过程类似，采用 ReLU 函数保证每层的特征值为正。

(4) 可视化技术的使用，可视化依赖于前三个操作，将各层神经网络都在做什么工作展示出来，为进行模型的调整优化提供了方向。

3.3 VGG(2014)

VGG 是 2014 年定位任务的第一名和分类任务的第二名。VGG 与 AlexNet 以及 ZFNet 结构相似，可以看作是其加深版本，并且在当时看来 VGG 已经是一个非常深的网络了。VGG 较之前网络模型的改进有：

(1) 采用 3x3 的小卷积核以及 2x2 的小池化核代替了原先较大的卷积核和池化核，减少卷积层的参数在学习到空间特征的同时可以有更多的非线性变化，能够较好地提取图像的特征和性质。

(2) 层数更深。基于前面提到的第一点改进，更小的卷积核带来了更深的网络深度，因而能够提取到的信息量也更多，这显著降低了错误率，并提高了模型的泛化能力。

(3) 全连接转卷积。首先这二者具有共同点，可以相互转化，但全连接层会将输入图片的大小限制成固定的。在测试阶段，网络模型将训练阶段使用的三个全连接层转化为卷积层，解除了全连接层带来的限制，因而可以接收任意宽和高的图片输入，大大降低了前期裁剪图片至固定大小的工作量，提高了网络工作效率。




Figure 6 VGG 对应论文引用量

3.4 GoogLeNet (2014)

GoogLeNet 在 2014 年的比赛中将 Top-5 错误率降至 6.67%，以较大的优势夺得分类任务的冠军。其最大的创新在于在网络结构中引入了 Inception 模块，因此这一年多 GoogLeNet 也被称为 Inception V1，后面还有其他改进版本。GoogLeNet 的特点有：

(1) 引入 Inception 结构，这是一种网中网 (Network In Network) 的结构，即原来的结点也是一个网络。这样在加深网络的同时加宽网络，网络结构稀疏却能产生稠密的数据，既提高了神经网络性能，又保证计算资源的使用效率。

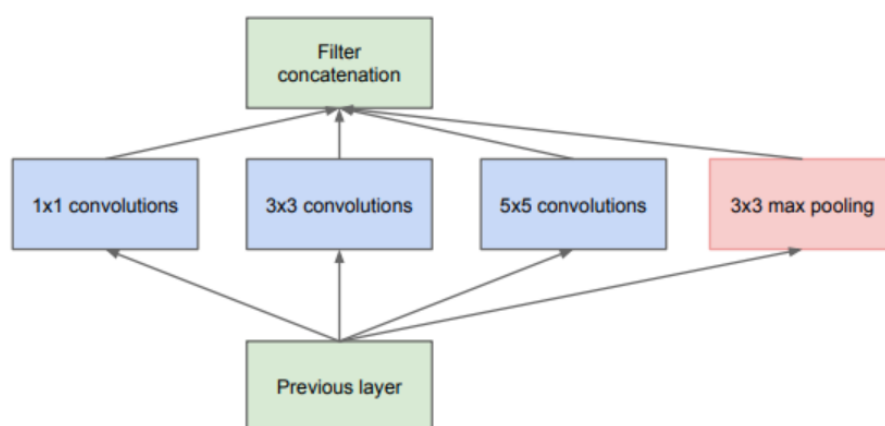


Figure 7 Inception 结构

(2) 使用 1x1 大小的卷积核以及采用全局平均池化层来代替全连接层，在不同角度减少所使用的参数量。GoogLeNet 的网络架构有 22 层，比 AlexNet 更深，但它只有 500 万的参数量，是 AlexNet 参数量的 1/12，大大降低了参数量和计算量，同时保证了准确率提高了效率。

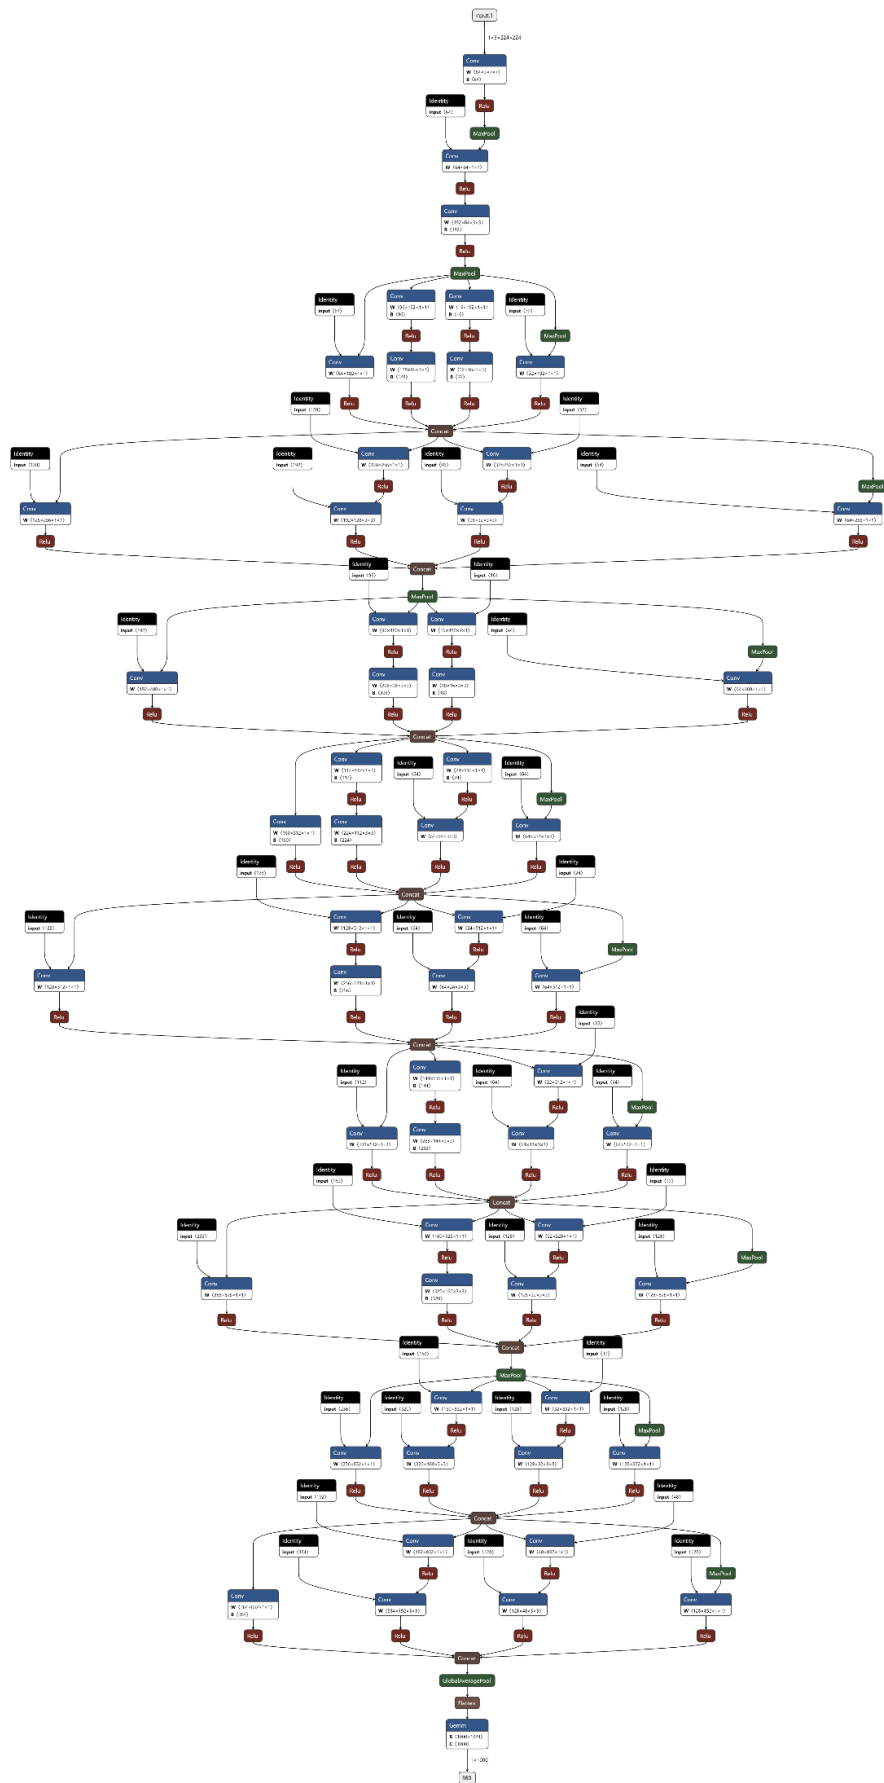


Figure 8 GoogLeNet 网络结构

3.5 ResNet (2015)

上述模型中或多或少都有通过增加网络深度来提高模型的性能，研究也的确证明使用更深层的网络模型能够提取到更加丰富的特征，准确率也越来越高，但随着网络深度继续增加，部分模型出现了准确率下降的情况，这是由于网络层数增加带来了梯度消失或梯度爆炸等问题。而 ILSVRC 2015 的冠军 ResNet 中的重大创新就是调整了网络结构，提出了残差模块和深度残差网络，解决了深层的神经网络难以训练的问题，也实现了里程碑式的突破。




Figure 10 ResNet 残差模块

ResNet 的主要创新点在于残差模块的提出。这可以理解成在网络的侧边打开了一条直达的通道，不再同原先一样直接学习输出特征，而是将输入特征与输出特征之间的残差作为主要的优化目标，例如 x 作为原始特征输入， $F(x)$ 是模型学习到的残差。这样的好处在于即使网络深度很深，有出现退化问题的可能，我们能够调整 $F(x)$ 部分的权重使其做恒等映射，即在当前层仍然保持最佳的网络状态。这可以看作是允许信息直接跳过一些层，从而在反向传播中有效地传递梯度，减轻了梯度消失和梯度爆炸问题，使得可以训练更深的网络。

3.6 GBD-Net (2016)

GBD-Net 是 ILSVRC 2016 的冠军模型，主要面向于目标

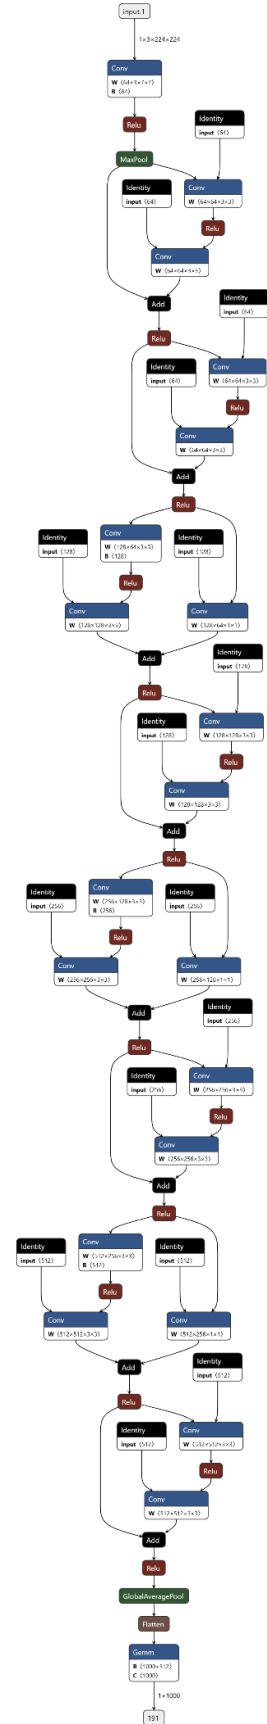


Figure 9
ResNet 网络结构

检测。它是在 Fast-RCNN 的基础上改进而来，而其核心算法仍是 ResNet，因此网络结构没有太大的改动。值得一提的是，作者在此模型中提出了门控双向神经网络，使得在特征学习和特征提取的过程中，能够在不同特征之间传递信息。

3.7 SENet (2017)

SENet 在 ImageNet 数据集上将 Top-5 错误率降低到 2.251%，夺得了最后一届 ILSVRC 分类任务的冠军。不同于先前模型提升性能的角度，SENet 引入了注意力机制，通过判断和学习特征通道之间的关系，来赋予重要特征以更大的权重，进而提高模型准确率和预测效果。




Figure 11 Squeeze 与 Excitation 结构

实现上述目标所需的重要结构为 Squeeze 和 Excitation，SENet 也是以此命名的。Squeeze 表示特征压缩，我们按照空间维度，将每个二维的特征通道对应到一个实数，即获得一个和通道数对应的一维向量，它表征了特征通道上响应的全局分布，并且即使是靠近输入的层也可以获得全局的信息。Excitation 对第一步得出的一维向量做非线性变换，将其得到的结果作为权重，完成对特征重要性的重新标度。

3.8 对可视化的解释

3.8.1 气泡图

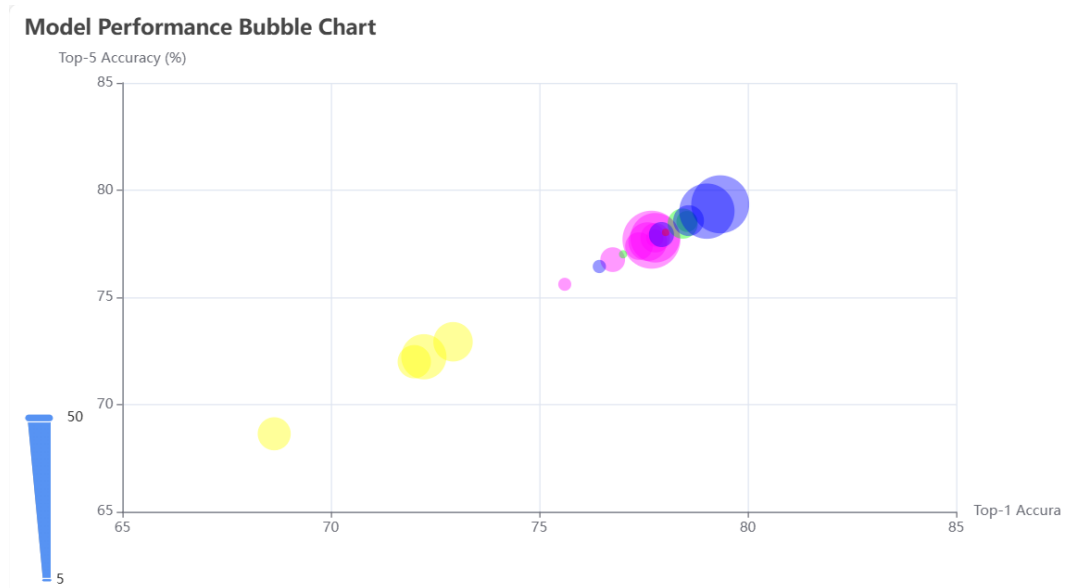


Figure 12 气泡图示例

数据来源:

采用 torchvision 的 cifar100 (一个包含 100 个类别, 每个类别有 600 张 32x32 彩色图像的数据集) 为训练数据对于各种计算机视觉神经网络模型进行性能测试, 选取在四种学习率下 (0.1, 0.02, 0.004, 0.0008; 同时控制 total epoch 为 200) 准确率最高的作为模型性能参考数据, 并且保存对应的参数量级 (params)。

<https://github.com/weiaicunzai/pytorch-cifar100>

x 轴映射的是 Top1Accuracy, 实为 1-Top1err, Top1 error (也称为分类误差或准确率的补数) 是指模型在预测类别时, 选择的置信度最高的类别 (即 top-1 预测) 与真实类别不匹配的比例。换句话说, 它是模型预测错误的比例。如果一个模型的 top1 error 是 30%, 这意味着在 70% 的情况下, 模型能够正确地预测出测试数据的真实类别。x 轴坐标体现的是模型精确预测的能力。

y 轴映射的是 Top5Accuracy, 实为 1-Top5err。Top5 error 是在 top1 error 基础上的一个扩展, 它考虑了模型预测的前五个最可能的类别。如果在这五个类别中至少有一个是正确的, 那么这个预测就被认为是正确的。Top5 error 衡量的是在这五个预测中没有包含真实类别的比例。y 轴坐标体现的是模型模糊预测的能力。

气泡位于对角线意味着模型精确预测与模糊预测的能力相仿；位于对角线上方意味着模型更擅长模糊预测；反之亦然。

模型参数量级（params）映射为气泡图的半径，半径越大参数越多。结合半径与气泡距原点距离一定程度上可以反应模型的效率：离原点越远同时半径越小意味着模型用更少的参数达成更高准确率，效率更高；反之亦然。

各个版本模型按组分类（如 vgg11_bn、vgg13_bn、vgg16_bn、vgg19_bn 为一组），映射到颜色通道上，在前端网页中，与右侧关于计算机网络发展结构图交互可以实现高亮显示对应的模型图标。

3.8.2 柱状图

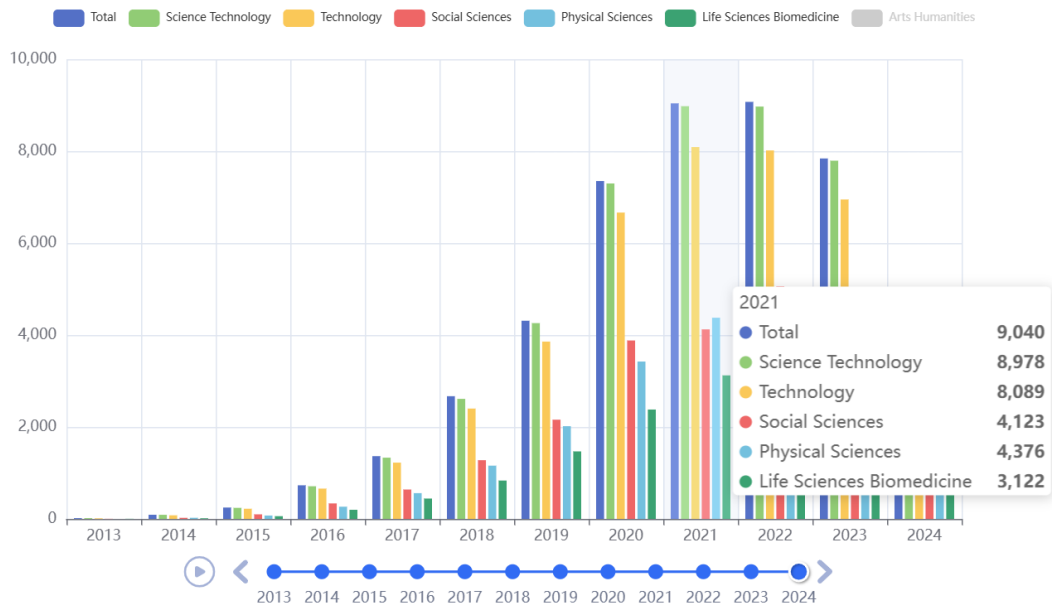


Figure 13 柱状图示例

数据来源：Web of Science

选取了文章中列举的经典 CNN 模型所对应的论文，收集论文逐年以及在各研究领域中引用量数据。

柱状图横坐标表示年份，纵坐标表示论文被引用次数。底部加入了动态时间轴，顶部图例列出了年引用总量以及研究领域，并将它们映射到不同的颜色，可以分别选中显示。

由于一篇论文涉及到的研究领域可能不止一个，故领域分类数据有部分重叠，无法做百分比堆积图。但我们仍然可以将各领域引用量和每一组左侧的年引用总

量进行对比，得到大致的占比。

4 CNN 走向何方？

从 CNN 之父 Yann LeCun 构建出 LeNet，到 2012 年以来 CNN 在图像分类任务上展现出来的强大性能，我们可以说，ILSVRC 的落幕，代表着人类宣告，当下的人工智能技术已经能够完全地胜任图像分类的任务。这是胜利的高潮，也是 CNN 能够代表计算机视觉领域的时代的终结，彼时，目标检测任务成为新的焦点，语义分割和识别任务也开始发展，一众新兴的计算机视觉模型和技术也日趋成熟。CNN 的未来，要走向何方呢？

4.1 持续优化！——DenseNet, EfficientNet

在 SENet 夺得冠军的 2017 年，还有一个网络模型在领域内崭露头角，它就是 DenseNet。虽然模型没有参加竞赛，但 Cornell 大学团队发表的论文 *Densely Connected Convolutional Networks* 在顶会 CVPR 上获得了 Best Paper 的殊荣。笔者也曾想过通过全连接的方式来提高网络中信息的传播效率和参数的复用价值，而 DenseNet 证实了笔者的幻想。

ResNet 以后，CNN 网络层数发生了数量级式的增长，伴随而来的是信息传播效率的难度陡然上升，梯度消失和梯度爆炸的问题十分棘手。DenseNet 吸取了 ResNet 和 Inception 模型中的精华部分，在模型参数、复杂度不增反降的情况下，实现了性能的又一次提升。其创新模块 dense block 的结构概念如下图所示，最鲜明的特征就是密集连接，优势主要在以下 3 点：

- 梯度传播：全连接使梯度更容易传播到前序层数，有效地缓解了梯度消失和梯度爆炸的问题。
- 特征复用：后续层数可以接收到每一层的特征，方便提取了更具表征能力的特征。
- 参数效率提升：尽管全连接看似低效，但上述两项优势使得 DenseNet 不需要庞大的体量就可以拥有优秀的性能，在与 ResNet 的同数据集比较中，DenseNet 的总体参数量和运算量都要小一些。




Figure 14 dense block 模块

除去架构思想的优化外，对于网络参数的优化取得了一定的成果。2019 年，EfficientNet 通过网络缩放的方法，优化了输入分辨率 r 、网络深度 $depth$ 和宽度（width，也即 channels）实现了性能和效率上的提升。

4.2 目标检测——CNN 还能走多远？

正如我们前文中所提到，图像分类是计算机视觉识别任务中最基础的一项，在这一任务得到解决以后，目标检测任务成为主要的研究方向，目标检测任务相较于图像分类任务对精准性的要求更高，也更贴近于实际场景，是计算机视觉走向实践、投入生产实际的重要一环。提到目标检测，那就不得不提到 YOLO（You Only Look Once）。

YOLO 是一个主要面向目标检测任务的算法系列，通过将目标检测视为一个单一的回归问题，直接从图像像素到边界框坐标和类别概率的预测，实现了快速的检测速度。这一设计突破了传统的滑动窗口和区域提议方法，显著提升了检测速度。早在 2015 年，Joseph Redmon, Santosh Divvala, Ross Girshick, 和 Ali Farhadi 就提出首个版本 YOLOv1；当然在这一时期，CNN 的研究也开始进军目标检测任务，发展出了 RCNN→Fast RCNN→Faster RCNN 一系列完成目标检测任务的算法。CNN 也曾一度展现出了胜任这一方向的能力，如 2016 年 ILSVRC 的冠军 GBDNet 就是在 Fast RCNN 基础上改进的，具有不错的目标检测能力。但站在上帝的视角上，我们看到了，YOLO 最终在角逐中胜出。从 YOLOv4 版本开始，这一模型系列就展现出来很强大统治力，尤其是在 MS COCO 这类以目标检测为主的数

据集的表现上，CNN 与其还是存在一定的差距。此后在越来越复杂的小目标检测、动态检测等任务中，CNN 昨日的光芒在逐渐消逝，可能，它就要成为过去了吧……

方法名称	主干网络	AP	AP ⁵⁰	AP ⁷⁵	AP ^S	AP ^M	AP ^L	年份
SSD ^[47]	Res101	31.2	50.4	33.3	10.2	34.5	49.8	2016
RetinaNet ^[122]	Res101-FPN	39.1	59.1	42.3	21.8	42.7	50.2	2017
FPN ^[51]	Res101-FPN	36.2	59.1	39.0	18.2	39.0	48.2	2017
Mask R-CNN ^[72]	Res101-FPN	38.2	60.3	41.7	20.1	41.1	50.2	2017
Deformable R-F CN ^[38]	Aligned-Inceptio n-ResNet	37.5	58.0	40.8	19.4	40.1	52.5	2017
Cascade R-CN N ^[25]	Res101-FPN	42.8	62.1	46.3	23.7	45.5	55.2	2018
YOLOv3 ^[137]	Darknet-53	33.0	57.9	34.4	18.3	35.4	41.9	2018
FCOS ^[102]	ResNeXt-101	44.7	64.1	48.4	27.6	47.5	55.6	2019
DCnv2 ^[138]	Res101-Deforma bleV2	46.0	67.9	50.8	27.8	49.1	59.5	2019
TridentNet ^[139]	Res101	42.7	63.6	46.5	23.9	46.6	56.6	2019
Cascade+Ran k-NMS ^[140]	Res101-FPN	43.2	61.8	47.0	24.6	46.2	55.4	2019
ATSS ^[104]	ResNeXt-101 + DCN	50.7	68.9	56.3	33.2	52.9	62.4	2020
TSD ^[141]	SENet154 + DCN	51.2	71.9	56.0	33.8	54.8	64.2	2020
Deformable DET R ^[142]	ResNeXt-101 + DCN	52.3	71.9	58.1	34.4	54.4	65.6	2020
HCE Cascade R-CNN ^[70]	Res101-FPN	46.5	65.6	50.6	27.4	49.9	59.4	2020
EfficientDet ^[143]	EfficientNet	55.1	74.3	59.9				2020
Scaled-YOLOv 4 ^[134]	CSP-P7	55.4	73.3	60.7	38.1	59.5	67.4	2020

Figure 15 YOLO 在 MS COCO 中表现优秀

4.3 Transformer——廉颇老矣，尚能饭否？

2020 年，Alexey Dosovitskiy 为代表的 Google Research 团队首次将 Transformer 框架用于计算机视觉任务（ViT），彼时，这个当下正在改变着人工智能领域的模型还在试验阶段，却已经在 CV 任务中展现出来与 CNN 旗鼓相当的实力。此后，整个领域发生了变化，生成式加入了计算机视觉要解决的任务当中，成为了相当重要的话题。在这个时代，CNN 真的成为历史了嘛？

卷积就像一把钥匙，打开了深度学习在计算机视觉领域的大门，我们有理由相信，CNN 不会退场。近几年的前沿研究中，CNN 在多模态领域展现出许多模型不具备的灵活性，同时 CNN 因其可理解性和易上手的特点，在许多技术领域仍在广泛的应用。相信未来，CNN 还会带给我们更多的惊喜吧。

References

- [1] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [2] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.
- [3] Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4700-4708.
- [4] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.
- [5] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [6] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 1-9.
- [7] Zeiler M D, Fergus R. Visualizing and understanding convolutional networks[C]//Computer Vision–ECCV 2014: 13th European Conference, Zurich, Switzerland, September 6-12, 2014, Proceedings, Part I 13. Springer International Publishing, 2014: 818-833.
- [8] Zeng X, Ouyang W, Yan J, et al. Crafting gbd-net for object detection[J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 40(9): 2109-2123.



课程作业检测系统 文本复制检测报告单(简洁)

№:BC202406301831194886941030

检测时间:2024-06-30 18:31:19

篇名: 21-刘澍泽-吴戈瑶-彭朗-期末报告.docx

作者: 吴戈瑶(2022311632)

授课教师: 迟钰雪

检测机构: 中央财经大学

文件名: 21-刘澍泽-吴戈瑶-彭朗-期末报告.docx

检测系统: 课程作业检测系统(课程学习全过程综合培养平台)

检测类型: 课程作业

检测范围: 中国学术期刊网络出版总库
中国博士学位论文全文数据库/中国优秀硕士学位论文全文数据库
中国重要会议论文全文数据库
中国重要报纸全文数据库
中国专利全文数据库
图书资源
优先出版文献库
互联网资源(包含贴吧等论坛资源)
英文数据库(涵盖期刊、博硕、会议的英文数据以及德国Springer、英国Taylor&Francis 期刊数据库等)
港澳台学术文献库
互联网文档资源
源代码库
CNKI大成编客-原创作品库
大学生论文联合比对库
课程作业联合比对库
机构自建比对库

时间范围: 1915-01-01至2024-06-30

检测结果

总文字复制比: 10.6%

跨语言检测结果: 0%

去除引用文献复制比: 10.6%

去除本人文献复制比: 10.6%

单篇最大文字复制比: 3.5% (移动端轻量级卷积神经网络的设计与实现)

重复字数: [1039] 总段落数: [1]
总字数: [9839] 疑似段落数: [1]
单篇最大重复字数: [344] 前部重合字数: [29]
疑似段落最大重合字数: [1039] 后部重合字数: [1010]
疑似段落最小重合字数: [1039]



指标: ☐ 疑似剽窃观点 ☒ 疑似剽窃文字表述 ☐ 疑似整体剽窃 ☐ 过度引用

相似表格: 0 相似公式: 没有公式 疑似文字的图片: 0

1. 21-刘澍泽-吴戈瑶-彭朗-期末报告.docx

总字数: 9839

相似文献列表

去除本人文献复制比: 10.6%(1039) 去除引用文献复制比: 10.6%(1039) 文字复制比: 10.6%(1039) 疑似剽窃观点: (0)

1	移动端轻量级卷积网络的设计与实现	3.5% (344)
	浦晶舜 - 《大学生论文联合比对库》- 2021-05-27	是否引证: 否
2	移动端轻量级卷积神经网络的设计与实现	3.5% (344)
	浦晶舜 - 《大学生论文联合比对库》- 2021-05-31	是否引证: 否
3	基于深度学习的垃圾分类算法研究	2.4% (233)
	黄艳熔 - 《大学生论文联合比对库》- 2023-05-25	是否引证: 否
4	论文1.1	2.3% (224)
	巩傲凡 - 《大学生论文联合比对库》- 2020-05-29	是否引证: 否
5	基于caffe框架与ONNX的神经网络模型转换的研究与实现	1.1% (109)
	- 《大学生论文联合比对库》- 2023-03-10	是否引证: 否
6	3617000016王勤伟_基于CNN的图像识别	0.9% (92)
	- 《大学生论文联合比对库》- 2019-06-14	是否引证: 否
7	1911701-李奕霖-面向神经网络图像分类的可视化系统开发	0.9% (89)
	李奕霖 - 《大学生论文联合比对库》- 2023-05-05	是否引证: 否
8	基于R-FCN的目标检测算法研究	0.7% (66)
	石智豪 - 《大学生论文联合比对库》- 2018-05-23	是否引证: 否
9	16151010129-王亚博-基于深度学习的人脸识别系统	0.7% (64)
	王亚博 - 《大学生论文联合比对库》- 2021-06-02	是否引证: 否
10	16151010129-王亚博-基于深度学习的人脸识别系统	0.7% (64)
	王亚博 - 《大学生论文联合比对库》- 2021-06-02	是否引证: 否
11	面向学术图片的深度学习分类模型构建研究	0.6% (63)
	江梓枫 - 《大学生论文联合比对库》- 2020-05-14	是否引证: 否
12	20214489231806840_蔡颖婕_图像识别对抗样本生成	0.6% (61)
	蔡颖婕 - 《高职高专院校联合比对库》- 2018-05-24	是否引证: 否
13	2_田毓鑫_基于卷积神经网络的巡线机器人线路本体识别研究与应用	0.6% (56)
	田毓鑫 - 《大学生论文联合比对库》- 2020-03-09	是否引证: 否
14	201708522_田毓鑫_基于卷积神经网络的巡线机器人线路本体识别研究与应用	0.6% (56)
	田毓鑫 - 《高职高专院校联合比对库》- 2020-03-13	是否引证: 否
15	1348014陈思沂毕业论文初稿	0.5% (53)
	陈思沂 - 《大学生论文联合比对库》- 2017-06-08	是否引证: 否
16	基于改进yolo模型的高分辨率遥感图像目标检测方法研究	0.5% (52)
	陈国力 - 《大学生论文联合比对库》- 2023-06-08	是否引证: 否
17	王敏一论文定稿	0.5% (47)
	王敏 - 《大学生论文联合比对库》- 2020-06-10	是否引证: 否
18	卷积神经网络研究综述	0.4% (36)
	张亚倩; - 《信息通信》- 2018-11-15	是否引证: 否
19	计算机软件技术在大数据系统中的应用	0.3% (34)
	霍怡雨;胡贤; - 《集成电路应用》- 2024-01-10	是否引证: 否
20	面向虚拟现实模拟飞行训练的手势视觉交互方法研究	0.3% (29)
	李湘蕙 - 《大学生论文联合比对库》- 2017-05-07	是否引证: 否
21	基于计算机视觉的变形监测系统设计与开发	0.3% (29)
	李泉志 - 《大学生论文联合比对库》- 2020-06-01	是否引证: 否

说明: 1. 总文字复制比: 被检测论文总重合字数在总字数中所占的比例

2. 去除引用文献复制比: 去除系统识别为引用的文献后, 计算出来的重合字数在总字数中所占的比例

3. 去除本人文献复制比: 去除作者本人文献后, 计算出来的重合字数在总字数中所占的比例

-
4. 单篇最大文字复制比：被检测文献与所有相似文献对比后，重合字数占总字数的比例最大的那一篇文献的文字复制比
 5. 复制比：按照“四舍五入”规则，保留1位小数
 6. 指标是由系统根据《学术论文不端行为的界定标准》自动生成的
 7. 红色文字表示文字复制部分；绿色文字表示引用部分（包括系统自动识别为引用的部分）；棕灰色文字表示系统依据作者姓名识别的本人其他文献部分
 8. 本报告单仅对您所选择的比对时间范围、资源范围内的检测结果负责



✉ amlc@cnki.net

🌐 <https://check.cnki.net/>

CNKI课程作业检测系统